## Московский государственный технический университет им. Н. Э. Баумана

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №2

«Методы построения моделей машинного обучения»

Вариант № 5

Выполнила:	Проверил:
Буйдина К.А.	Гапанюк Ю.Е
группа ИУ5-63Б	

Дата: 11.04.25 Дата:

Подпись: Подпись:

Задание:

Номер варианта: 5

Методы: дерево решений и случайный лес

Номер набора данных, указанного в задаче: 5

https://www.kaggle.com/datasets/khushikyad001/world-happiness-report

Задача №1.


Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик).

Ход выполнения:

```
import pandas as pd
import numpy as np
data = pd.read_csv('world_happiness_report.csv')
print(data.head())
print("\nИнформация о датасете:")
print(data.info())
print("\nПропущенные значения:")
print(data.isnull().sum())
print("\n0писательная статистика:")
print(data.describe())
 max
        2024.000000
                            8.000000
                                         59980.720000
                                                             1.000000
        Healthy_Life_Expectancy
                                      Freedom
                                                Generosity \
                    4000.000000 4000.000000 4000.000000
 count
 mean
                      67.917605
                                     0.502723
                                                  0.143960
                      10.172091
                                     0.285219
                                                  0.200088
 std
 min
                      50.000000
                                     0.000000
                                                 -0.200000
 25%
                      59.177500
                                     0.260000
                                                 -0.030000
 50%
                      68.015000
                                     0.500000
                                                  0.140000
 75%
                      76.690000
                                     0.750000
                                                  0.310000
                      85.000000
                                     1.000000
                                                  0.500000
 max
        Corruption_Perception Unemployment_Rate Education_Index
                  4000.000000
                                                       4000.000000
 count
                                      4000.000000
                                                          0.750385
 mean
                     0.498920
                                        10.966748
                     0.288866
                                         5.210712
                                                          0.144819
 std
                     0.000000
                                         2.000000
                                                          0.500000
 min
 25%
                     0.240000
                                         6.450000
                                                          0.630000
 50%
                     0.500000
                                        10.995000
                                                          0.750000
 75%
                                        15.450000
                     0.742500
                                                          0.880000
```

```
numeric_cols = data.select_dtypes(include=['float64', 'int64']).columns
data[numeric_cols] = data[numeric_cols].fillna(data[numeric_cols].mean())
print(data.isnull().sum())
 Country
                              0
                              0
 Year
 Happiness_Score
                              0
 GDP_per_Capita
 Social_Support
                              0
 Healthy_Life_Expectancy
                              0
 Freedom
                              0
                              0
 Generosity
 Corruption_Perception
                              0
                              0
 Unemployment_Rate
 Education_Index
                              0
 Population
                              0
 Urbanization_Rate
                              0
 Life_Satisfaction
                              0
 Public_Trust
                              0
                              0
 Mental_Health_Index
 Income_Inequality
                              0
 Public_Health_Expenditure
                             0
 Climate_Index
                              0
 Work_Life_Balance
                              0
from sklearn.preprocessing import LabelEncoder
encoder = LabelEncoder()
data['Country_encoded'] = encoder.fit_transform(data['Country'])
data.drop('Country', axis=1, inplace=True)
```

```
corr_matrix = data.corr()
print(corr_matrix['Happiness_Score'].sort_values(ascending=False))
import seaborn as sns
sns.pairplot(data[['GDP_per_Capita', 'Social_Support', 'Happiness_Score']])
 GDP_per_Capita
                              0.016324
 Work_Life_Balance
                              0.016085
 Public_Trust
                              0.015138
 Corruption_Perception
                              0.015096
 Life_Satisfaction
                              0.014920
 Healthy_Life_Expectancy
                              0.012658
                              0.009508
 Social_Support
                              0.007505
 Crime_Rate
                              0.003758
 Internet_Access
                              0.003275
 Education_Index
                              0.002752
 Climate_Index
                             -0.001834
 Public_Health_Expenditure
                             -0.003977
 Employment_Rate
                             -0.004209
 Generosity
                             -0.004796
 Urbanization_Rate
                             -0.004861
 Country_encoded
                             -0.009397
 Mental_Health_Index
                             -0.013628
 Population
                             -0.021352
 Income_Inequality
                             -0.022347
```



```
features = X.columns
plt.figure(figsize=(12, 6))
plt.barh(features, feature_importances)
         Employment_Rate
Political_Stability
 Climate_Index
Public_Health_Expenditure
       Income_Inequality
Mental_Health_Index
           Public_Trust
Life_Satisfaction
         Urbanization_Rate
Population
Education_Index
     Unemployment_Rate
Corruption_Perception
  Healthy_Life_Expectancy
Social_Support
Теперь можно построить более точные модели, используя только наиболее значимые признаки
selected_features = ['Employment_Rate', 'Crime_Rate', 'Internet_Access', 'Work_Life_Balance', 'Mental_Health_Index',
y = data['Happiness_Score']
plt.figure(figsize=(10, 6))
sns.boxplot(data=X[selected_features], orient='h')
```



```
from sklearn.metrics import (
   mean_absolute_error,
   mean_squared_error,
   median_absolute_error,
   explained_variance_score,
   max_error
def evaluate_model(y_true, y_pred, model_name):
   print(f"\n{model_name} Metrics:")
   print(f"- MAE: {mean_absolute_error(y_true, y_pred):.3f}")
   print(f"- MSE: {mean_squared_error(y_true, y_pred):.3f}")
   print(f"- RMSE: {np.sqrt(mean_squared_error(y_true, y_pred)):.3f}")
    print(f"- MedAE: {median_absolute_error(y_true, y_pred):.3f}")
   print(f"- Explained Variance: {explained_variance_score(y_true, y_pred):.3f}")
   print(f"- Max Error: {max_error(y_true, y_pred):.3f}")
# Для дерева
evaluate_model(y_test, y_pred_tree, "Decision Tree")
evaluate_model(y_test, y_pred_forest, "Random Forest")
 Decision Tree Metrics:
 - MAE: 1.291
 - MSE: 2.277
 - RMSE: 1.509
 - MedAE: 1.262
 - Explained Variance: -0.105
 - Max Error: 4.260
 Random Forest Metrics:
 - MAE: 1.262
 - MSE: 2.123
 - RMSE: 1.457
 - MedAE: 1.242
 - Explained Variance: -0.031
 - Max Error: 2.793
```